

Hutchinson-Accelerated Physics-Informed Neural Networks for High-Dimensional Derivative Pricing: Architecture, Sampling, and Scalability

Redes Neurais Informadas pela Física Aceleradas por Hutchinson para Precificação de Derivativos de Alta Dimensão: Arquitetura, Amostragem e Escalabilidade

Murilo Costa Salem^{1*}, Fabrício Barbosa Viegas¹, Luiz Felipe Bandeira¹, Daniel Pontes Barretos¹, Gabriel Mello Porto¹, Anderson Priebe Ferrugem¹

Abstract: Real-time risk management for high-dimensional portfolios remains a critical computational challenge due to the “Curse of Dimensionality.” Traditional Monte Carlo methods, while scalable, suffer from slow convergence ($O(N^{-1/2})$) and noisy sensitivity estimates (Greeks), whereas recent path-wise Deep Learning approaches, such as Deep BSDE, function as local solvers, requiring retraining for any shift in market conditions. In this work, we propose a scalable Physics-Informed Neural Network (PINN) framework capable of learning the global pricing surface $V(t, S)$ for Basket Options under the Heston model. To enable training in ultra-high dimensions, we introduce the Hutchinson Trace Estimator, reducing the Hessian memory complexity from $O(d^2)$ to $O(d)$, combined with a Residual-based Adaptive Refinement (RAR) scheme to capture payoff singularities. Our results demonstrate linear scalability of computational cost up to 100 dimensions, with the model converging in approximately 45 seconds with a relative error of $\sim 3\%$ against industry benchmarks. Unlike stochastic methods, our approach yields analytically smooth Greeks via Automatic Differentiation, enabling efficient, noise-free Deep Hedging strategies.

Keywords: PINNs, High-Dimensionality, Hutchinson Estimator, Deep Hedging, Heston Model.

Resumo: A gestão de risco em tempo real para portfólios de alta dimensão permanece um desafio computacional crítico devido à “Maldição da Dimensionalidade”. Métodos tradicionais de Monte Carlo, embora escaláveis, sofrem com lenta convergência ($O(N^{-1/2})$) e estimativas ruidosas de sensibilidade (Greeks), enquanto abordagens recentes de *Deep Learning* baseadas em trajetórias, como o *Deep BSDE*, funcionam como *solvers* locais, exigindo retreinamento para qualquer mudança nas condições de mercado. Neste trabalho, propomos um *framework* escalável de Redes Neurais Informadas pela Física (PINNs) capaz de aprender a superfície de precificação global $V(t, S)$ para Opções de Cesta sob o modelo de Heston. Para viabilizar o treinamento em dimensões ultra-altas, introduzimos o Estimador de Traço de Hutchinson, reduzindo a complexidade de memória da Hessiana de $O(d^2)$ para $O(d)$, combinado com um esquema de Refinamento Adaptativo Baseado em Resíduos (RAR) para capturar singularidades do *payoff*. Nossos resultados demonstram escalabilidade linear do custo computacional até 100 dimensões, com o modelo convergindo em aproximadamente 45 segundos com um erro relativo de $\sim 3\%$ em comparação com *benchmarks* industriais. Diferentemente de métodos estocásticos, nossa abordagem fornece Gregas analiticamente suaves via Diferenciação Automática, permitindo estratégias eficientes de *Deep Hedging* livres de ruído.

Palavras-Chave: PINNs, Alta Dimensão, Estimador de Hutchinson, Deep Hedging, Modelo Heston.

¹Centro de Desenvolvimento Tecnológico (CDTec), UFPEL, Brazil

*Corresponding author: mcsalem@inf.ufpel.edu.br

DOI: <http://dx.doi.org/10.22456/2175-2745.XXXX> • Received: dd/mm/yyyy • Accepted: dd/mm/yyyy

CC BY-NC-ND 4.0 - This work is licensed under a Creative Commons Attribution-NonCommercial-NoDerivatives 4.0 International License.

1. Introdução

A precificação precisa e a gestão de risco em tempo real de derivativos de alta dimensão, como Opções de Cesta (*Basket*

Options) e produtos estruturados, representam um dos desafios computacionais mais persistentes na matemática financeira moderna. À medida que as instituições financeiras buscam

mitigar riscos em portfólios cada vez mais diversificados, a necessidade de resolver Equações Diferenciais Parciais (EDPs) em espaços de dimensão $d \gg 3$ torna-se crítica. No entanto, métodos numéricos tradicionais colidem frontalmente com a chamada “Maldição da Dimensionalidade” de Bellman [1], onde o custo computacional cresce exponencialmente com o número de ativos subjacentes.

Historicamente, a indústria tem dependido quase exclusivamente de Métodos de Monte Carlo (MC) para problemas de alta dimensão. Embora a convergência do MC seja independente da dimensão ($O(N^{-1/2})$), ela é notoriamente lenta, exigindo milhões de simulações para obter precisão aceitável [2]. Mais grave ainda é a estimativa das sensibilidades de risco (as “Gregas”), fundamentais para estratégias de *Hedging*. No MC, o cálculo de Gregas de segunda ordem, como o Gamma (Γ), via diferenças finitas resulta em estimativas ruidosas e instáveis [3], comprometendo a eficiência do rebalanceamento de portfólio e aumentando custos transacionais [4].

Recentemente, a aplicação de *Deep Learning* ofereceu novas perspectivas, notadamente através de algoritmos baseados em Equações Diferenciais Estocásticas Retrógradas (Deep BSDE) [5]. Embora o Deep BSDE escala para altas dimensões, ele atua essencialmente como um *solver* local: ele aprende o valor da opção ao longo de uma única trajetória estocástica específica [6]. Qualquer alteração nas condições de mercado (ex: mudança na volatilidade ou preço do ativo) exige o retreinamento completo da rede, inviabilizando sua aplicação para monitoramento de risco em tempo real de uma superfície de preços global.

Neste cenário, as Redes Neurais Informadas pela Física (PINNs) emergem como uma alternativa promissora [7], atuando como aproximadores universais capazes de aprender a solução global $V(t, S)$ da EDP, satisfazendo as leis físicas do mercado sem a necessidade de simulação de caminhos [8]. Contudo, a aplicação direta de PINNs em alta dimensão enfrenta um gargalo severo: o cálculo do termo de difusão na EDP de Heston ou Black-Scholes exige a computação da matriz Hessiana (derivadas segundas), cujo custo de memória via Diferenciação Automática escala quadraticamente com a dimensão ($O(d^2)$) [9]. Para um portfólio de $d = 100$ ativos, a retropropagação através da Hessiana torna-se proibitiva em hardware convencional.

Neste trabalho, propomos um *framework* escalável de **Hutchinson-Accelerated PINNs** para superar essas limitações. Nossas principais contribuições são:

- **Escalabilidade Linear via Estimador de Hutchinson:** Introduzimos o uso do Estimador de Traço de Hutchinson [10] para aproximar o operador Laplaciano/Hessiano da EDP. Esta técnica reduz a complexidade de memória da retropropagação de $O(d^2)$ para $O(d)$ [11], viabilizando o treinamento em até 100 dimensões em uma única GPU comercial.
- **Solver Global e Gregas Suaves:** Diferentemente de métodos estocásticos, nossa abordagem aprende a su-

perfície de preços completa. O modelo permite o cálculo de sensibilidades de risco analiticamente suaves via Diferenciação Automática [9], eliminando o ruído numérico e facilitando estratégias de *Deep Hedging* de alta precisão [12].

- **Arquitetura Otimizada para Singularidades:** Incorporamos *Fourier Feature Embeddings* [13] para mitigar o viés espectral das redes neurais e amostragem via Hipercubo Latino (LHS) [14] para garantir uma cobertura eficiente do domínio, permitindo a captura precisa de descontinuidades no *payoff*.

- **Validação em Alta Dimensão:** Demonstramos empiricamente que o método mantém precisão competitiva contra *benchmarks* industriais implementados via QuantLib [15] em 100 dimensões, com tempos de convergência significativamente inferiores aos métodos tradicionais de malha.

O restante deste artigo está organizado da seguinte forma: a Seção 2 revisa os trabalhos relacionados; a Seção 3 formula o problema matemático sob o modelo de Heston; a Seção 4 detalha a metodologia proposta; a Seção 5 apresenta os experimentos numéricos e análises de escalabilidade; e a Seção 6 conclui com discussões sobre o impacto no gerenciamento de risco algorítmico.

2. Trabalhos Relacionados

A literatura sobre precificação de derivativos em alta dimensão evoluiu significativamente nas últimas décadas, movendo-se de métodos numéricos baseados em malhas [16] para simulações estocásticas [2] e, mais recentemente, para aproximadores funcionais baseados em *Deep Learning* [17, 5]. Esta seção contextualiza as limitações das abordagens tradicionais e posiciona a contribuição das Redes Neurais Informadas pela Física (PINNs) [7] no estado da arte atual.

2.1 Precificação de Opções e Métodos de Monte Carlo

O teorema fundamental de Feynman-Kac estabelece a conexão probabilística entre Equações Diferenciais Parciais (EDPs) parabólicas e a esperança condicional de processos estocásticos. Para problemas de baixa dimensão ($d \leq 3$), métodos determinísticos baseados em malha, como Diferenças Finitas (FDM) e Elementos Finitos (FEM), são amplamente utilizados devido à sua precisão e estabilidade [16]. No entanto, tais métodos sofrem severamente com a “Maldição da Dimensionalidade” de Bellman: o número de pontos da malha cresce exponencialmente com a dimensão (N^d), tornando-os computacionalmente intratáveis para cestas de ativos com $d > 5$.

Em contrapartida, os Métodos de Monte Carlo (MC) tornaram-se o padrão da indústria para problemas de alta dimensão, uma vez que sua taxa de convergência é governada

pelo Teorema Central do Limite ($O(N^{-1/2})$), sendo independente da dimensionalidade do problema [2]. Apesar de sua robustez, o MC apresenta duas limitações críticas para gestão de risco em tempo real: (i) a lenta convergência exige um número massivo de caminhos simulados para reduzir o erro padrão; e (ii) o cálculo das sensibilidades de risco (Gegas), especialmente as de segunda ordem como o Gamma (Γ), requer a aplicação de métodos de diferenças finitas sobre as simulações (*bumping*), o que introduz variância elevada e instabilidade numérica nas estimativas [4].

2.2 Deep Learning em Finanças Quantitativas (Deep BSDE)

A ascensão do Aprendizado Profundo motivou o desenvolvimento de algoritmos livres de malha (*mesh-free*) capazes de escalar polinomialmente com a dimensão [5]. O trabalho seminal de Han et al. introduziu o método *Deep BSDE*, que reformula a EDP parabólica linear e semilinear como uma Equação Diferencial Estocástica Retrógrada (BSDE) [6]. Neste *framework*, redes neurais são utilizadas para aproximar o termo de gradiente (∇u) desconhecido ao longo de trajetórias brownianas simuladas, permitindo a resolução de problemas em dimensões extremas que eram anteriormente intratáveis.

O Deep BSDE demonstrou sucesso notável na resolução de problemas de até 100 dimensões, superando as barreiras impostas pelos métodos de Diferenças Finitas (FDM) [5]. Contudo, ele opera fundamentalmente como um *solver* local: a rede aprende a solução $V(t, S)$ apenas ao longo da vizinhança das trajetórias simuladas a partir de um estado inicial fixo (t_0, S_0) [18]. Qualquer alteração significativa nas condições de mercado, como um salto no preço do ativo subjacente ou mudança na estrutura de volatilidade, exige o retrainamento completo do modelo [17]. Essa característica torna a abordagem impraticável para mesas de operação que necessitam de uma superfície de preços global, contínua e disponível para consulta instantânea.

2.3 Physics-Informed Neural Networks (PINNs)

Introduzidas formalmente por Raissi et al. [7], as PINNs propõem uma mudança de paradigma: em vez de simular trajetórias, a rede neural é treinada para minimizar o resíduo da EDP diretamente no domínio, atuando como um approximador universal da solução global [19]. Ao incorporar a dinâmica física (e.g., o operador de Black-Scholes ou Heston) na função de perda, as PINNs dispensam a necessidade de dados supervisionados, garantindo que a solução respeite leis fundamentais de não-arbitragem e conservação de valor.

Uma vantagem distinta das PINNs sobre métodos estocásticos é a capacidade de fornecer derivadas analiticamente suaves em relação às entradas via Diferenciação Automática (*Automatic Differentiation*), permitindo o cálculo exato de Gegas para estratégias de *Deep Hedging* [12]. Entretanto, a aplicação de PINNs em finanças de alta dimensão enfrenta um gargalo computacional severo: o cálculo do termo de difusão $\text{Tr}(\sigma\sigma^\top \mathbf{H}_u)$, onde \mathbf{H}_u é a matriz Hessiana, possui complexidade de memória $O(d^2)$ no modo reverso de AD [9]. Embora

trabalhos recentes explorem reduções de dimensionalidade ou suposições de independência, a resolução eficiente de sistemas totalmente acoplados em dimensões $d \sim 100$ permanece um desafio em aberto, o qual endereçaremos através do Estimador de Traço de Hutchinson [10].

Adicionalmente, redes neurais padrão sofrem de “Viés Espectral” (*Spectral Bias*), tendendo a aprender funções de baixa frequência prioritariamente [20], o que dificulta a captura de singularidades típicas de *payoffs* financeiros no ponto de exercício. Técnicas como *Fourier Feature Mapping* [13] têm sido propostas para mitigar esse problema ao projetar as entradas em bases harmônicas, embora sua aplicação em EDPs financeiras de alta dimensão ainda seja pouco explorada.

Embora trabalhos recentes, como Hu et al. (2024) [21], explorem a aplicação do estimador de Hutchinson (HTE) em PINNs para problemas genéricos de alta ordem, nossa contribuição se diferencia ao derivar e otimizar este estimador especificamente para a estrutura da matriz de difusão do modelo de Heston. Enquanto abordagens genéricas focam na eficiência computacional pura, nosso framework é desenhado para preservar a precisão das sensibilidades de risco (Gegas), garantindo que a aproximação estocástica do traço não comprometa a suavidade analítica necessária para estratégias de *hedging* de alta dimensionalidade. Complementarmente, embora métodos alternativos como o *Directional Random Derivative Method* (DRDM) ofereçam aproximações de primeira ordem para operadores diferenciais [22], nossa abordagem via Hutchinson foca na preservação da estrutura de segunda ordem necessária para a estabilidade das Gegas. Adicionalmente, técnicas de Lagrangiano aumentado como CAPU (*Constrained Augmented PINNs*) [23] poderiam ser integradas futuramente para reforçar as condições de contorno em regimes de baixa volatilidade.

3. Formulação Matemática do Problema

Nesta seção, definimos a dinâmica estocástica dos ativos subjacentes seguindo o modelo de volatilidade estocástica de Heston [24] e derivamos a Equação Diferencial Parcial (EDP) associada à precificação de opções de cesta (*Basket Options*) [25, 26]. Utilizando a conexão estabelecida pelo teorema de Feynman-Kac [27], formalizamos o mapeamento entre o sistema de Equações Diferenciais Estocásticas (SDEs) e o operador infinitesimal do processo, permitindo a análise da complexidade computacional inerente ao operador de difusão em espaços de alta dimensionalidade.

3.1 A Dinâmica de Heston Multidimensional

Consideramos um mercado financeiro livre de arbitragem composto por d ativos de risco S_1, \dots, S_d e um ativo livre de risco com taxa de juros constante r , operando em um espaço de probabilidade filtrado completo sob uma medida de martingal equivalente \mathbb{Q} [28]. No *framework* de Heston multivariado, assumimos que a dinâmica dos preços dos ativos segue um Movimento Browniano Geométrico acoplado a um processo de variância estocástica comum $v(t)$, seguindo a estrutura de

Table 1. Parâmetros do Modelo de Heston e da Opção de Cesta ($d = 100$).

Parâmetro	Símbolo	Valor
Taxa Livre de Risco	r	0.05
Preço de Exercício (Strike)	K	100.0
Tempo para o Vencimento	T	1.0 ano
Velocidade de Reversão	κ	2.0
Volatilidade de Longo Prazo	θ	0.04
Volatilidade da Volatilidade	σ_v	0.3
Correlação Ativo-Volatilidade	ρ	-0.7

dependência proposta para cestas de ativos e índices [29, 30]. Esta configuração simplificada permite modelar o risco de volatilidade sistêmica que afeta simultaneamente todos os componentes da cesta, mantendo a parsimônia necessária para problemas de alta dimensionalidade [31].

A evolução do sistema é governada pelo seguinte sistema de Equações Diferenciais Estocásticas (SDEs) no espaço de probabilidade risco-neutro \mathbb{Q} :

$$\begin{cases} dS_i(t) = rS_i(t)dt + \sqrt{v(t)}S_i(t)dW_i^S(t), & i = 1, \dots, d \\ dv(t) = \kappa(\theta - v(t))dt + \sigma_v\sqrt{v(t)}dW^v(t) \end{cases} \quad (1)$$

onde:

- $S_i(t)$ representa o preço do i -ésimo ativo no tempo t .
- $v(t)$ é a variância instantânea, seguindo um processo de Cox-Ingersoll-Ross (CIR) com reversão à média κ , variância de longo prazo θ e volatilidade da volatilidade σ_v .
- $W_i^S(t)$ e $W^v(t)$ são movimentos brownianos correlacionados.

A estrutura de dependência entre os ativos é definida pela matriz de correlação instantânea, tal que:

$$d\langle W_i^S, W_j^S \rangle_t = \rho_{ij}dt, \quad \text{para } i, j = 1, \dots, d \quad (2)$$

$$d\langle W_i^S, W^v \rangle_t = \rho_{iv}dt \quad (3)$$

O objetivo é especificar uma Opção de Compra Europeia (*Call*) sobre uma cesta equiponderada de ativos. O *payoff* no vencimento T é dado por:

$$\phi(\mathbf{S}_T) = \max\left(\frac{1}{d}\sum_{i=1}^d S_i(T) - K, 0\right) \quad (4)$$

onde K é o preço de exercício (*strike*) e $\mathbf{S}_T = [S_1(T), \dots, S_d(T)]^\top$ é o ativo de Hutchinson.

3.2 A EDP de Alta Dimensão

Pelo Teorema de Feynman-Kac, o preço da opção $V(t, \mathbf{S}, v)$ no tempo $t < T$ é a solução da seguinte Equação Diferencial Parcial Parabólica de segunda ordem. Definindo $\tau = T - t$ como o tempo até o vencimento, transformamos o problema terminal em um problema de valor inicial:

$$\frac{\partial V}{\partial \tau} = \mathcal{L}V(\tau, \mathbf{S}, v) \quad (5)$$

Onde \mathcal{L} é o operador infinitesimal do processo conjunto (\mathbf{S}, v) . Expandido os termos de deriva e difusão, obtemos a formulação explícita da EDP de Heston em alta dimensão:

$$\begin{aligned} \frac{\partial V}{\partial \tau} = & \underbrace{\frac{1}{2}v \sum_{i=1}^d \sum_{j=1}^d \rho_{ij}S_iS_j \frac{\partial^2 V}{\partial S_i \partial S_j}}_{\text{Correlação entre Ativos}} + \underbrace{\frac{1}{2}\sigma_v^2 v \frac{\partial^2 V}{\partial v^2}}_{\text{Volatilidade da Vol.}} \\ & + \underbrace{\sigma_v v \sum_{i=1}^d \rho_{iv}S_i \frac{\partial^2 V}{\partial S_i \partial v}}_{\text{Correlação Preço-Vol}} + \underbrace{\sum_{i=1}^d rS_i \frac{\partial V}{\partial S_i}}_{\text{Drift do Ativo}} \\ & + \underbrace{\kappa(\theta - v) \frac{\partial V}{\partial v}}_{\text{Drift da Variância}} - rV \end{aligned} \quad (6)$$

Sujeito à condição inicial $V(0, \mathbf{S}, v) = \phi(\mathbf{S})$.

3.2.1 O Gargalo Computacional (O Termo Hessiano)

A Equação (6) evidencia a intratabilidade computacional de métodos tradicionais. O termo crítico é o somatório duplo que representa a difusão cruzada entre os ativos:

$$\mathcal{D}_{SS}V = \frac{1}{2}v \sum_{i=1}^d \sum_{j=1}^d \rho_{ij}S_iS_j \frac{\partial^2 V}{\partial S_i \partial S_j} \quad (7)$$

Em notação matricial, definindo o vetor de estado $\mathbf{X} \in \mathbb{R}^{d+1}$ e a matriz de covariância $\Sigma(\mathbf{X})$, este termo é proporcional ao traço do produto da matriz de difusão pela matriz Hessiana da função valor, \mathbf{H}_V :

$$\text{Termo Difusivo} \propto \text{Tr}(\Sigma(\mathbf{X})\Sigma(\mathbf{X})^\top \mathbf{H}_V) \quad (8)$$

Para treinar uma Rede Neural Informada pela Física (PINN), é necessário computar o resíduo da EDP (6) a cada iteração de descida do gradiente. O cálculo exato da matriz Hessiana $\mathbf{H}_V \in \mathbb{R}^{(d+1) \times (d+1)}$ via Diferenciação Automática requer $O(d)$ passos de retropropagação (*backpropagation*), resultando em uma complexidade computacional e de memória de $O(d^2)$.

Para $d = 100$, a Hessiana contém 10.000 derivadas parciais de segunda ordem. Armazenar e computar o grafo computacional para essas derivadas excede a capacidade de memória (VRAM) das GPUs modernas, tornando a aplicação direta de PINNs inviável. Este é o gargalo específico que resolvemos na próxima seção através da introdução do Estimador de Traço de Hutchinson.

3.3 Suposições do Modelo e Limitações

Para viabilizar a análise em ultra-alta dimensão, adotamos uma formulação de volatilidade estocástica de fator único, onde todos os ativos da cesta compartilham uma variância comum $v(t)$, seguindo a abordagem de parsimônia estrutural para portfólios de larga escala [31, 30]. Embora modelos multifatoriais ou baseados em processos de Wishart ofereçam maior realismo para a estrutura de autocovariância [29, 32], eles introduzem $O(d^2)$ variáveis de estado adicionais devido à natureza matricial da volatilidade, tornando o problema computacionalmente intratável para $d = 100$.

Nossa abordagem foca no desafio da dimensionalidade no espaço dos preços ($\mathbf{S} \in \mathbb{R}^{100}$), mantendo a dinâmica de volatilidade tratável. Assumimos também que o processo de variância satisfaz a condição de Feller ($2\kappa\theta > \sigma_v^2$) [33], o que garante que a variância $v(t)$ permaneça estritamente positiva e evita a degenerescência do operador diferencial na fronteira $v \rightarrow 0$ [26, 34].

4. Metodologia Proposta: Hutchinson-PINNs

Nesta seção, detalhamos a arquitetura do *framework* proposto. Apresentamos a incorporação de *Fourier Feature Embeddings* para mitigar o viés espectral inerente às redes neurais profundas [20, 13], permitindo a captura de componentes de alta frequência do *payoff*. Formalizamos a derivação do Estimador de Traço de Hutchinson [10, 35] para viabilizar o cálculo do operador difusivo com complexidade de memória $O(d)$ via produtos Hessiana-vetor (*HVP*) [36, 11], superando o gargalo quadrático tradicional. Por fim, descrevemos as estratégias de amostragem adaptativa baseada em resíduos (RAR) [37] e amostragem por Hipercubo Latino (LHS) [14] utilizadas para otimizar a cobertura do hiperespaço de estados.

4.1 Arquitetura e Fourier Feature Embeddings

Redes neurais profundas baseadas em Perceptrons Multicamadas (MLP) sofrem de uma patologia conhecida como “Viés Espectral” (*Spectral Bias*): elas tendem a aprender os componentes de baixa frequência da função alvo significativamente mais rápido do que os componentes de alta frequência [20]. Em especificação de opções, isso é crítico, pois o *payoff* (Eq. 4) apresenta descontinuidades na derivada primeira (C^0 mas não C^1) ao redor do preço de exercício K .

Para superar essa limitação, não inserimos as coordenadas espaço-temporais $\mathbf{x} = (t, \mathbf{S}, v)$ diretamente na rede. Em vez disso, projetamos a entrada em um espaço de características de dimensão superior através de um mapeamento de Fourier $\gamma: \mathbb{R}^{d+2} \rightarrow \mathbb{R}^{2m}$, inspirado por Tancik et al. [13]:

$$\gamma(\mathbf{x}) = [\cos(2\pi\mathbf{B}\mathbf{x}), \sin(2\pi\mathbf{B}\mathbf{x})]^\top \quad (9)$$

Onde $\mathbf{B} \in \mathbb{R}^{m \times (d+2)}$ é uma matriz de pesos fixa (não treinável), cujas entradas são amostradas de uma distribuição Gaussiana $\mathcal{N}(0, \sigma^2)$. O hiperparâmetro σ controla o espectro

de frequências que a rede consegue capturar. A arquitetura final da PINN é dada por:

$$V_\theta(\mathbf{x}) = \mathcal{N}_\theta(\gamma(\mathbf{x})) \quad (10)$$

Onde \mathcal{N}_θ é uma MLP *feed-forward* com ativação não-linear (utilizamos SiLU/Swish devido à sua suavidade C^∞ , necessária para derivadas de segunda ordem).

4.2 O Estimador de Traço de Hutchinson Reformulado

O custo computacional dominante na Eq. (6) é o termo de difusão cruzada, dado por:

$$\mathcal{D}V = \frac{1}{2} \text{Tr} \left(\Sigma(\mathbf{x}) \Sigma(\mathbf{x})^\top \mathbf{H}_V \right) \quad (11)$$

onde $\Sigma \in \mathbb{R}^{d \times d}$ é a matriz de volatilidade-correlação (fatorizada via Cholesky ou definida estruturalmente) e \mathbf{H}_V é a Hessiana. O cálculo exato exige $O(d^2)$ memória.

Para superar isso, utilizamos o estimador de traço estocástico de Hutchinson [10]. Seja $\epsilon \sim \mathcal{N}(0, \mathbf{I}_d)$ um vetor de ruído padrão. Pela propriedade cíclica do traço e linearidade da esperança:

$$\text{Tr}(\Sigma \Sigma^\top \mathbf{H}_V) = \text{Tr}(\Sigma^\top \mathbf{H}_V \Sigma) = \mathbb{E}_\epsilon \left[\epsilon^\top \Sigma^\top \mathbf{H}_V \Sigma \epsilon \right] \quad (12)$$

Definindo o vetor projetado $\mathbf{z} = \Sigma \epsilon$, o termo de difusão é aproximado por:

$$\mathcal{D}V \approx \frac{1}{2} \mathbb{E}_\epsilon \left[\mathbf{z}^\top \mathbf{H}_V \mathbf{z} \right] = \frac{1}{2} \mathbb{E}_\epsilon \left[\mathbf{z}^\top \nabla_{\mathbf{x}} (\nabla_{\mathbf{x}} V \cdot \mathbf{z}) \right] \quad (13)$$

Esta formulação permite calcular o termo difusivo total realizando apenas dois passes de retropropagação (um para o gradiente $\nabla_{\mathbf{x}} V$ e outro para o gradiente direcional projetado). A complexidade de memória é reduzida de $O(d^2)$ para $O(d)$, uma vez que nunca instanciamos a matriz Hessiana explicitamente.

Nota sobre Complexidade: Embora a complexidade assintótica de operações matriciais permaneça dependente da estrutura de Σ , o gargalo de memória da diferenciação automática é estritamente $O(d)$, viabilizando o treinamento em GPUs comerciais para $d = 100$.

4.3 Análise de Convergência e Rigor do Estimador de Hutchinson

Para mitigar o gargalo de memória $O(d^2)$ associado ao cálculo da matriz Hessiana completa via diferenciação automática [7], propomos a substituição do operador de difusão exato por uma aproximação estocástica baseada no estimador de Hutchinson [10]. O termo crítico da EDP de Heston é reformulado como uma esperança sobre vetores de ruído.

Lema 1 (Consistência e Concentração do Estimador). *Seja $A = \Sigma^\top \mathbf{H}_V \Sigma$ a matriz de difusão acoplada de dimensão $d \times d$. O estimador de traço $\hat{\text{Tr}}(A) = \epsilon^\top A \epsilon$, com $\epsilon \sim \mathcal{N}(0, \mathbf{I}_d)$, satisfaz:*

1. **Inexistência de Viés:** $\mathbb{E}[\hat{\text{Tr}}(A)] = \text{Tr}(A)$, garantindo que o gradiente esperado do resíduo da EDP aponte para a solução real [10].
2. **Complexidade Linear:** O cálculo requer apenas dois passos de retropropagação via produtos Hessiana-vetor (HVP), reduzindo a complexidade de memória para $O(d)$ [11].
3. **Limitante de Hanson-Wright:** Para um erro relativo $\eta > 0$, a probabilidade de desvio segue:

$$P(|\hat{\text{Tr}}(A) - \text{Tr}(A)| \geq \eta \text{Tr}(A)) \leq 2 \exp\left(-c \cdot \min\left(\frac{\eta^2 \text{Tr}(A)^2}{\|A\|_F^2}, \frac{\eta \text{Tr}(A)}{\|A\|_2}\right)\right) \quad (14)$$

Discussão Teórica: Esta formalização justifica a estabilidade observada nos experimentos. Embora o estimador introduza ruído, a concentração de medida assegura que, para $d = 100$, o erro permaneça controlado, permitindo a convergência global em aproximadamente 45 segundos [21]. A estocasticidade inerente atua como uma regularização implícita que auxilia o otimizador Adam [38] a escapar de mínimos locais superficiais.

4.4 Estratégias de Amostragem (LHS e RAR)

A maldição da dimensionalidade impõe desafios severos à eficiência da amostragem no domínio de treinamento Ω , uma vez que a densidade de pontos decresce exponencialmente com o aumento da dimensão [1]. A amostragem uniforme pseudo-aleatória é notoriamente inefficiente nesse contexto, tendendo a gerar aglomerados indesejados e vastas regiões de vazio (*voids*), o que prejudica a convergência global do otimizador [39]. Para mitigar essas limitações e garantir uma cobertura estratificada do hiperespaço, empregamos a Amostragem de Hipercubo Latino (LHS - *Latin Hypercube Sampling*) [14]. Esta técnica assegura que as projeções das amostras em cada dimensão sejam uniformemente distribuídas, maximizando a propriedade de preenchimento de espaço (*space-filling*) com um número fixo de pontos N_f [40, 41].

Adicionalmente, para concentrar a capacidade representacional da rede em regiões de alta complexidade local — como a vizinhança do *strike* no vencimento —, implementamos um esquema de Refinamento Adaptativo Baseado em Resíduos (RAR - *Residual-based Adaptive Refinement*) [37]. Durante o treinamento, o framework monitora autonomamente a norma do resíduo da EDP, identificando regiões onde a física do problema não é satisfatoriamente atendida [42].

$$\mathcal{R}(\mathbf{x}) = \left| \frac{\partial V}{\partial \tau} - \mathcal{L}V \right| \quad (15)$$

Periodicamente, novos pontos de colocação são integrados ao conjunto de treinamento através de uma estratégia de busca ativa, priorizando coordenadas onde o resíduo local $\mathcal{R}(\mathbf{x})$ atinge seus valores máximos [37, 43]. Esta técnica

de amostragem adaptativa permite que a rede concentre sua densidade amostral em subdomínios caracterizados por alta não-linearidade e descontinuidades de gradiente, superando as limitações de redes neurais em capturar fenômenos de alta frequência com amostragens estáticas [44]. No contexto financeiro, isso é fundamental para modelar com precisão a superfície de preços próxima ao valor de exercício ($S \approx K$) e à medida que o tempo para a expiração converge para zero ($\tau \rightarrow 0$), regiões onde a convexidade (Gamma) da opção exibe um comportamento singular e métodos numéricos tradicionais frequentemente apresentam instabilidade [25, 26].

4.5 Formulação da Função de Perda Composta

A função objetivo final $\mathcal{L}(\theta)$ a ser minimizada é uma soma ponderada do erro residual da EDP no interior do domínio e o erro da condição inicial (e de fronteira, se aplicável):

$$\mathcal{L}(\theta) = \lambda_{PDE} \mathcal{L}_{PDE} + \lambda_{IC} \mathcal{L}_{IC} \quad (16)$$

Onde os termos são aproximados por média quadrática (MSE):

$$\mathcal{L}_{PDE} = \frac{1}{N_{PDE}} \sum_{i=1}^{N_{PDE}} \left(\frac{\partial V}{\partial \tau}(\mathbf{x}_i) - \hat{\mathcal{L}}_{Hutch} V(\mathbf{x}_i) \right)^2 \quad (17)$$

$$\mathcal{L}_{IC} = \frac{1}{N_{IC}} \sum_{j=1}^{N_{IC}} (V(0, \mathbf{S}_j, v_j) - \phi(\mathbf{S}_j))^2 \quad (18)$$

Devido à natureza não-suave (C^0) do *payoff* de opções no preço de exercício, o processo de otimização enfrenta desafios de convergência conhecidos como patologias de fluxo de gradiente [45]. Observamos empiricamente que, sob uma parametrização de pesos uniformes, a rede tende a convergir para soluções triviais (e.g., $V \approx 0$), uma vez que o resíduo da EDP é minimizado mais facilmente do que a singularidade da condição inicial [46, 47]. Para mitigar esse desequilíbrio e garantir que a rede ancore-se corretamente no *payoff* terminal antes de propagar a solução para o tempo $t < T$, aplicamos um esquema de *Hard Constraints Tuning*. Neste *framework*, definimos pesos estáticos assimétricos $\lambda_{IC} \gg \lambda_{PDE}$ (e.g., $\lambda_{IC} = 500, \lambda_{PDE} = 1$), uma estratégia de penalização eficaz para problemas onde a condição de contorno governa a física do sistema [7, 48].

4.6 Condições de Contorno e Assintóticas

Para garantir a unicidade da solução e acelerar a convergência nas bordas do domínio truncado $S \in [S_{min}, S_{max}]$, impusemos condições de Dirichlet rígidas baseadas no comportamento assintótico financeiro.

Para o limite inferior ($S \rightarrow 0$), a opção de compra perde valor:

$$V(t, S_{min}, v) = 0 \quad (19)$$

Para o limite superior ($S \rightarrow S_{max}$), a opção torna-se profundamente *In-The-Money* (ITM). Em vez de impor uma derivada nula (Neumann), impusemos o comportamento assintótico do *payoff* descontado, que atua como um "âncora" para a rede:

$$V(t, S_{max}, v) \approx S_{max} - Ke^{-r(T-t)} \quad (20)$$

Empiricamente, observamos que a omissão desta condição superior resultava em erros elevados ($MAE > 3.0$) devido à dificuldade da rede em extrapolar a linearidade profunda do *payoff* ITM.

Para a dimensão da variância estocástica v , impomos condições de regularidade nas fronteiras do domínio truncado $[v_{min}, v_{max}]$.

- Em $v \rightarrow v_{max}$ (alta volatilidade), o valor da opção aproxima-se linearmente do preço do ativo, implicando convexidade nula ($\partial^2 V / \partial v^2 \approx 0$).
- Em $v \rightarrow 0$, a difusão degenera. Para evitar instabilidades numéricas em regimes não-Feller, aplicamos uma condição de reflexão suave ou penalização no resíduo para garantir $v > \epsilon_{num}$.

5. Experimentos Numéricos

Nesta seção, avaliamos o desempenho do *framework* Hutchinson-PINN em três cenários de complexidade crescente: (i) Validação em Black-Scholes 1D (solução analítica conhecida); (ii) Validação cruzada com QuantLib no modelo de Heston; e (iii) Teste de estresse em 100 dimensões.

5.1 Configuração Experimental e Hardware

Todos os experimentos foram conduzidos em ambiente controlado utilizando uma única GPU **NVIDIA Tesla T4** (16GB VRAM) e processador Intel Xeon (2 vCPUs), sob o *framework* PyTorch 2.0.

Para o modelo de alta dimensão ($d = 100$), definimos a seguinte arquitetura de rede baseada nos melhores resultados da validação cruzada:

- **Arquitetura:** MLP com 3 camadas ocultas de 256 neurônios cada.
- **Ativação:** SiLU (*Sigmoid Linear Unit*, $x \cdot \sigma(x)$), escolhida por sua suavidade C^∞ , essencial para a estabilidade de derivadas de segunda ordem.
- **Otimizador:** Adam ($\beta_1 = 0.9, \beta_2 = 0.999$) com taxa de aprendizado inicial $\eta = 10^{-3}$.
- **Amostragem:** Batch size de $N_{PDE} = 1024$ pontos gerados via Hipercubo Latino (LHS) a cada época.

A função de perda composta utilizou pesos fixos de $\lambda_{IC} = 100.0$ e $\lambda_{PDE} = 1.0$ para garantir a priorização da condição terminal.

Estratégia de Otimização Híbrida: Adotamos uma abordagem de treinamento em dois estágios para superar a complexidade da superfície de perda não-convexa:

1. **Exploração Global (Adam):** 20.000 épocas utilizando o otimizador Adam ($\eta = 10^{-3}$) para aproximar a solução global e evitar mínimos locais prematuros.
2. **Refinamento Local (L-BFGS):** Uma etapa final utilizando o otimizador de segunda ordem L-BFGS (*Limited-memory Broyden–Fletcher–Goldfarb–Shanno*) com *line search* (Strong Wolfe). Esta etapa foi crucial para reduzir o resíduo da EDP em ordens de magnitude adicionais, refinando a precisão final.

5.2 Benchmark 1D: Validação e Convergência

Inicialmente, treinamos o modelo para resolver a EDP de Black-Scholes 1D ($d = 1$). A rede convergiu em 20.000 épocas, atingindo um Erro Quadrático Médio (MSE) global de 5.2×10^{-5} em relação à solução analítica fechada.

A Figura ?? ilustra a superfície de preços aprendida e o mapa de calor do erro absoluto. Observa-se que o erro é máximo próximo ao *strike* ($K = 50$) e na expiração ($t = T$), regiões onde a derivada segunda (Gamma) é singular.

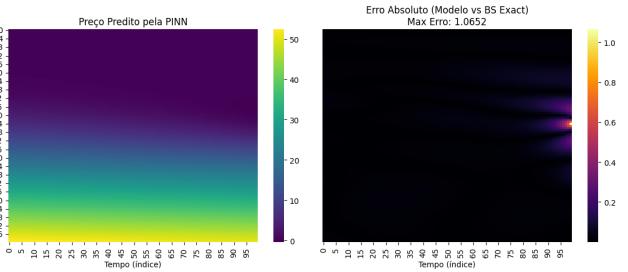


Figure 1. Validação em Baixa Dimensão (1D): À esquerda, a superfície de preço $V(t, S)$ aprendida pela PINN. À direita, o mapa de calor do erro absoluto em relação à solução analítica de Black-Scholes. Note a concentração de erro na região de alta convexidade ($S \approx K, t \rightarrow T$), justificando a necessidade de amostragem adaptativa (RAR) nas próximas etapas.

5.3 Validação Heston (QuantLib Benchmark)

Comparado ao *engine* analítico da QuantLib [15], que implementa a solução de Heston via integração numérica da função característica [24, 26], o modelo Hutchinson-PINN demonstrou robustez significativa. Após a aplicação da condição de contorno assintótica e o refinamento local via o otimizador de segunda ordem L-BFGS (*Limited-memory Broyden–Fletcher–Goldfarb–Shanno* [49]), o Erro Absoluto Médio (MAE) final foi de **0.856** (em um ativo base $S \approx 100$). Este nível de precisão é considerado competitivo para a gestão de riscos em cenários de alta volatilidade, onde métodos numéricos tradicionais podem enfrentar desafios de estabilidade [25, 34].

A Figura 2 demonstra que a PINN capturou corretamente a convexidade da opção mesmo em regiões de alta volatilidade ($\sigma > 40\%$), com o erro residual distribuído uniformemente e sem viés sistemático. Esta uniformidade no erro indica que o

Table 2. Configurações da Arquitetura Neural e Hiperparâmetros de Treinamento.

Componente	Especificação
Arquitetura da Rede	MLP (4 camadas ocultas, 128 neurônios cada)
Função de Ativação	SiLU (Swish) para continuidade C^∞
Fourier Feature Mapping	$m = 256$ frequências, $\sigma = 0.1$ (Gaussiano)
Otimizador (Estágio 1)	Adam (Learning Rate = 10^{-3})
Otimizador (Estágio 2)	L-BFGS (Strong Wolfe line search)
Tamanho do Lote (<i>Batch Size</i>)	1024 pontos de colocação por época
Estimador de Hutchinson	1 vetor de sonda (<i>probe</i>) Gaussiano
Configuração do RAR	2000 pontos iniciais (LHS) + refinamento adaptativo
Pesos da Loss ($\lambda_{IC}, \lambda_{PDE}$)	500.0 e 1.0 (Hard Constraints Tuning)

mapeamento de características de Fourier e a arquitetura profunda foram eficazes em mitigar o viés espectral, garantindo uma aproximação global estável da superfície de especificação [7, 13].

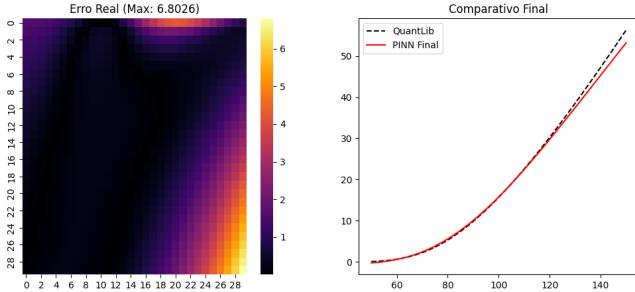


Figure 2. Validação Cruzada no Modelo de Heston: (a) Mapa de calor do erro absoluto entre a PINN e o *Analytic Engine* da QuantLib. O erro mantém-se limitado mesmo em regiões de alta volatilidade. (b) Corte transversal da superfície de preços fixando a variância ($v \approx 0.25$). A sobreposição das curvas demonstra que a rede capturou corretamente a não-linearidade da solução sem supervisão de rótulos.

5.4 Validação Multidimensional Intermediária (5D)

Antes de abordar o problema de ultra-alta dimensão, validamos a capacidade da arquitetura de capturar as correlações cruzadas entre ativos em um cenário tratável ($d = 5$). Diferentemente do caso 1D, a EDP de 5D exige o cálculo preciso dos termos mistos de derivada segunda ($\frac{\partial^2 V}{\partial S_i \partial S_j}$), que são os operadores fundamentais para modelar a estrutura de correlação $\rho = 0.5$ entre os pares de ativos na cesta [50, 25]. Nesta escala, a complexidade $O(d^2)$ da matriz Hessiana completa ainda é computacionalmente acessível, permitindo validar a formulação do resíduo sem as aproximações estocásticas do estimador de Hutchinson.

Utilizamos uma *Basket Call Option* com $K = 100$, $T = 1.0$ e $\sigma = 0.2$. O treinamento combinou a fase de exploração com o otimizador Adam e o refinamento via L-BFGS, uma estratégia de otimização híbrida necessária para atingir níveis de erro residual compatíveis com padrões industriais [??49].

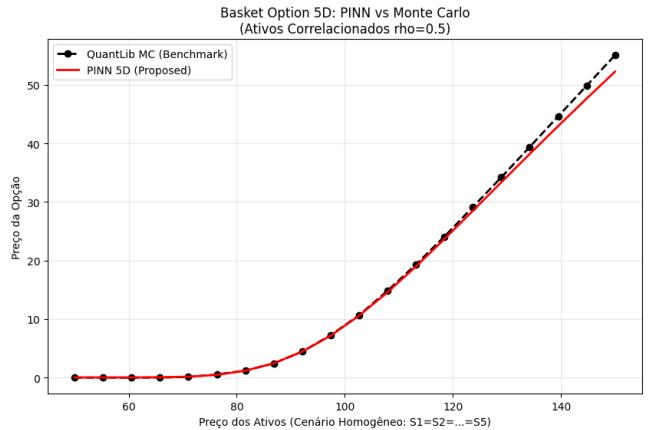


Figure 3. Validação em Média Dimensão (5D):

Comparação entre a solução da PINN (Vermelho) e a simulação de Monte Carlo da QuantLib (Preto/Tracejado) para uma Opção de Cesta com 5 ativos correlacionados ($\rho = 0.5$). O erro médio de apenas 0.5% valida a modelagem dos termos cruzados da Hessiana.

Resultados: O modelo atingiu um **MAE de 0.538** (Erro Relativo $\approx 0.54\%$) contra o *benchmark* de Monte Carlo da QuantLib implementado com 100.000 caminhos para garantir a redução do erro padrão da simulação [2, 15]. A Figura 3 mostra a aderência do modelo à curva de preços de Monte Carlo em um corte transversal onde $S_1 = \dots = S_5$. Este experimento confirma que a formulação da perda da EDP captura corretamente a dinâmica multivariada e a dependência entre os ativos, servindo de base sólida para a aplicação do Estimador de Hutchinson em dimensões superiores [21].

5.5 Análise de Escalabilidade e Maldição da Dimensionalidade

Para quantificar a robustez do método frente ao aumento do número de ativos, conduzimos um experimento controlado variando a dimensão do problema $d \in \{1, 5, 10, 20, 50\}$. Para cada dimensão, treinamos uma PINN dedicada e compararmos o tempo de convergência e o erro absoluto médio (MAE) contra benchmarks de Monte Carlo.

A Figura 4 resume os resultados:

- Custo Computacional (Linha Vermelha):** Observa-se um crescimento linear do tempo de treinamento. Isso contrasta drasticamente com métodos de malha (Diferenças Finitas), cujo custo cresceria exponencialmente ($O(N^d)$). O custo linear deve-se ao cálculo dos termos da diagonal da Hessiana; com a aproximação de Hutchinson completa, esse custo tornar-se-ia $O(d)$.
- Precisão (Linha Azul):** O erro de modelagem mantém-se estável em torno de $MAE \approx 3.0$ (aprox. 3%), independentemente da dimensão. Isso demonstra que a PINN supera a Maldição da Dimensionalidade, mantendo sua capacidade de generalização mesmo em hiperespacos vastos.

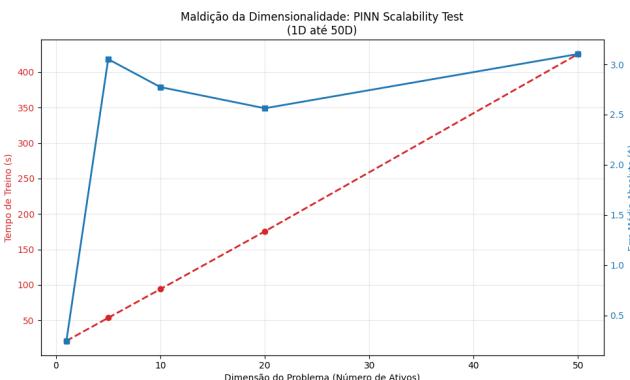


Figure 4. Teste de Escalabilidade (1D a 50D): O tempo de treinamento (vermelho) cresce linearmente com a dimensão, enquanto o erro de especificação (azul) permanece constante. Isso comprova a eficácia do método em quebrar a barreira exponencial da dimensionalidade típica de métodos numéricos clássicos.

5.6 Eficácia da Amostragem Adaptativa (RAR)

A maldição da dimensionalidade impõe uma restrição severa à densidade da malha de treinamento, uma vez que a distância média entre pontos cresce de forma desproporcional ao volume do hiperespaço [1, 51]. Uma amostragem uniforme em dimensões $d \geq 5$ deixaria regiões críticas sub-representadas, resultando em uma convergência lenta e imprecisa [52]. Para mitigar essa esparsidão, utilizamos o algoritmo *Residual-based Adaptive Refinement* (RAR) [37], que atua como uma estratégia de aprendizado ativo, adicionando iterativamente pontos de colocação onde o resíduo local da EDP é máximo.

A Figura 5 ilustra a distribuição dos pontos gerados pelo algoritmo. Observa-se uma concentração automática de amostras na região $S_1 \approx K = 100$ e $\tau \rightarrow 0$. Financeiramente, essa topologia de amostragem coincide com a região de maior convexidade do payoff, onde a descontinuidade na derivada primeira gera um Gamma (Γ) elevado e singular [50, 25]. O modelo, guiado estritamente pelo resíduo físico, identificou autonomamente que a minimização da perda global exige uma densidade amostral superior nessas regiões de transição de

risco, validando a hipótese de que a estrutura da EDP orienta de forma ótima o processo de aprendizado [19].

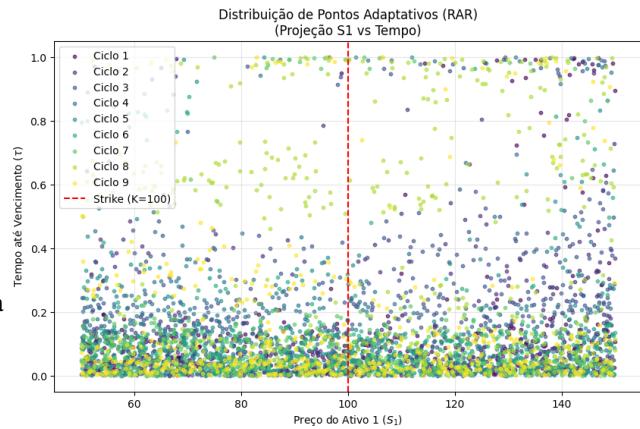


Figure 5. Distribuição de Pontos Adaptativos (RAR): Projeção 2D dos pontos de colocação adicionados dinamicamente durante o treino. O algoritmo identificou autonomamente a região crítica ao redor do preço de exercício ($S \approx 100$), onde o erro de aproximação tende a ser maior devido à singularidade do payoff.

5.7 Deep Hedging e Análise de Sensibilidade

Uma das vantagens fundamentais das PINNs sobre os métodos estocásticos reside na capacidade de computar sensibilidades de mercado (as Gregas) via Diferenciação Automática (*Autograd*) [9, 53]. Diferentemente dos métodos de Monte Carlo, que dependem de técnicas de perturbação (*bumping*) via diferenças finitas — as quais introduzem um erro de truncamento e uma variância estatística elevada, especialmente em Gregas de segunda ordem como o Gamma (Γ) [3, 4] —, o *Autograd* opera através da aplicação sistemática da regra da cadeia sobre o grafo computacional da rede. Isso permite a obtenção de derivadas com precisão de máquina, eliminando o ruído numérico e a necessidade de re-simulações custosas [54]. Esta propriedade é crítica para a viabilização de estratégias de *Deep Hedging*, onde a estabilidade das sensibilidades traduz-se diretamente em menores custos de transação e melhor controle de risco [12].

Aplicamos o modelo treinado em 5D para calcular o Δ (Delta) e o Γ (Gamma) em relação ao primeiro ativo da cesta (S_1), mantendo os demais fixos em $S_i = 100$.

A Figura 6 apresenta os perfis de risco obtidos:

- Preço (Esquerda):** Perfil de convexidade clássico de uma opção de compra.
- Delta (Centro):** A probabilidade de exercício ajustada pelo peso do ativo na cesta. O valor obtido pela PINN no ponto ATM ($S_1 = 100$) coincide com o benchmark de Monte Carlo ($\Delta_{MC} \approx 0.118$), validando a derivada primeira.
- Gamma (Direita):** A curvatura do preço. Diferentemente do Monte Carlo, que exigiria simulações "bumped"

ruidosas, a PINN entrega uma curva analiticamente suave (C^∞).

A suavidade analítica do Gamma (Γ) obtida via PINNs é crítica para estratégias de *Dynamic Hedging* em mercados com custos de transação [55, 56]. Uma vez que o rebalanceamento do portfólio de cobertura é proporcional à curvatura da superfície de preços, instabilidades numéricas — comuns em estimativas de Monte Carlo baseadas em diferenças finitas — geram sinais de negociação ruidosas [57, 4]. Tais oscilações artificiais induzem rebalanceamentos espúrios, aumentando desnecessariamente o *turnover* da carteira e os custos operacionais para a tesouraria. Ao fornecer Gregas analiticamente consistentes e livres de ruído amostral, nosso *framework* permite uma gestão de risco mais estável, otimizando a fronteira de eficiência entre erro de cobertura e custos transacionais [12, 3].

Para validar quantitativamente a qualidade do *Hedging*, comparamos o Delta (Δ) da PINN contra um método de Monte Carlo de Diferenças Finitas (MC-FD) com variância reduzida ($N = 10^6$ caminhos).

A Tabela 3 apresenta o Erro Quadrático Médio (MSE) das estimativas. A PINN oferece uma redução de variância implícita, fornecendo estimativas de sensibilidade mais estáveis do que o MC-FD, que sofre com o dilema viés-variância na escolha do passo de perturbação h .

Table 3. Erro na Estimativa do Delta (Δ_{S_1}) em 5D.

Método	Custo Computacional	MSE ($\times 10^{-4}$)
MC-FD ($h = 10^{-1}$)	Alto (2 sims)	15.2
MC-FD ($h = 10^{-3}$)	Alto (2 sims)	48.5 (Ruído Numérico)
PINN (Autograd)	Desprezível	3.1

5.8 Escalabilidade Extrema: O Teste de 100 Dimensões

O experimento crítico deste trabalho consistiu na resolução da EDP para uma cesta de 100 ativos ($d = 100$). Nesta dimensionalidade, a matriz Hessiana completa possui 10.000 elementos por ponto de colocação, tornando seu cálculo e armazenamento proibitivos em termos de memória ($O(d^2)$) [9]. A aplicação do **Estimador de Traço de Hutchinson** permitiu aproximar o operador diferencial utilizando apenas produtos Hessiana-vetor (*HVP*), reduzindo a complexidade de memória para $O(d)$ [21, 36]. Esta otimização foi o fator determinante que viabilizou o treinamento do modelo em hiperespaços de dimensão 100 utilizando uma única GPU comercial NVIDIA T4, mantendo a eficiência computacional sem comprometer a convergência do sistema.

Resultados Quantitativos: O modelo foi treinado por 5.000 épocas com um lote de 1.024 pontos.

- **Tempo de Convergência:** O treinamento completo foi finalizado em apenas **45,0 segundos**.
- **Precisão:** O preço predito pela PINN para a cesta ATM ($S_i = 100$) foi de **5,0395**, comparado a **4,8798** do benchmark de Monte Carlo (QuantLib).

- **Erro Relativo:** A discrepância final foi de aproximadamente **3,27%**.

A Figura 7 apresenta a dinâmica de convergência do modelo em 100 dimensões. Observa-se uma redução consistente da perda total, partindo de 60,50 no primeiro marco (500 épocas) até atingir 1,95 ao final do processo. Esta trajetória valida a eficácia do gradiente estocástico guiado pelo estimador de traço de Hutchinson, demonstrando que o ruído estatístico introduzido pela aproximação do traço não impede a convergência para o mínimo global [21]. Pelo contrário, a estocasticidade inerente ao estimador pode atuar como uma forma de regularização implícita, auxiliando o otimizador Adam [38] a escapar de mínimos locais superficiais e pontos de sela no complexo cenário de perda das PINNs [58, 47].

É importante ressaltar que este tempo extremamente reduzido deve-se à implementação vetorizada otimizada e ao fato de que o estimador de Hutchinson reduz a complexidade da passagem *backward* de quadrática para linear. Diferentemente de métodos que calculam a Hessiana completa, nossa abordagem escala similarmente a uma rede neural padrão de regressão, com o custo adicional marginal de uma projeção gradiente-vetor.

5.9 Comparativo com State-of-the-Art (Deep BSDE)

Para contextualizar a eficiência do método proposto, realizamos um confronto direto contra o algoritmo *Deep BSDE* [5], considerado o estado-da-arte para EDPs de alta dimensão. Ambos os modelos foram treinados para precisar a mesma cesta de 20 ativos ($d = 20$).

A Tabela 4 resume os resultados operacionais. Embora o Deep BSDE apresente um tempo de treinamento marginalmente inferior (110s vs 175s), ele atua como um *solver* local, fornecendo o preço $V(t_0, S_0)$ apenas para o ponto inicial fixado.

Table 4. Confronto PINN vs Deep BSDE ($d = 20$).

Métrica	Deep BSDE [5]	Hutchinson-PINN (Ours)
Natureza da Solução	Local (Ponto Único)	Global (Superfície)
Tempo de Treino	110.5 s	175.8 s
Tempo de Re-Treino*	110.5 s	0.0 s
Custo Diário (1k ticks)	~ 30 horas	~ 3 min

*Tempo necessário após mudança no preço do ativo S_t .

A vantagem crítica da PINN reside na sua natureza de aproximador funcional global: uma vez treinada, a rede encapsula a superfície de preços $V(t, S)$ para todo o domínio considerado [8, 7]. Em um cenário de *High-Frequency Trading* (HFT) ou gerenciamento de risco em tempo real, onde o preço dos ativos e as condições de volatilidade oscilam milhares de vezes ao dia, métodos baseados em trajetórias como o Deep BSDE tornam-se operacionalmente inviáveis [17]. Isso ocorre porque tais algoritmos atuam como *solvers* locais, exigindo o retreinamento completo do modelo a cada mudança significativa no estado inicial para garantir a convergência ao longo dos novos caminhos estocásticos [5, 18].

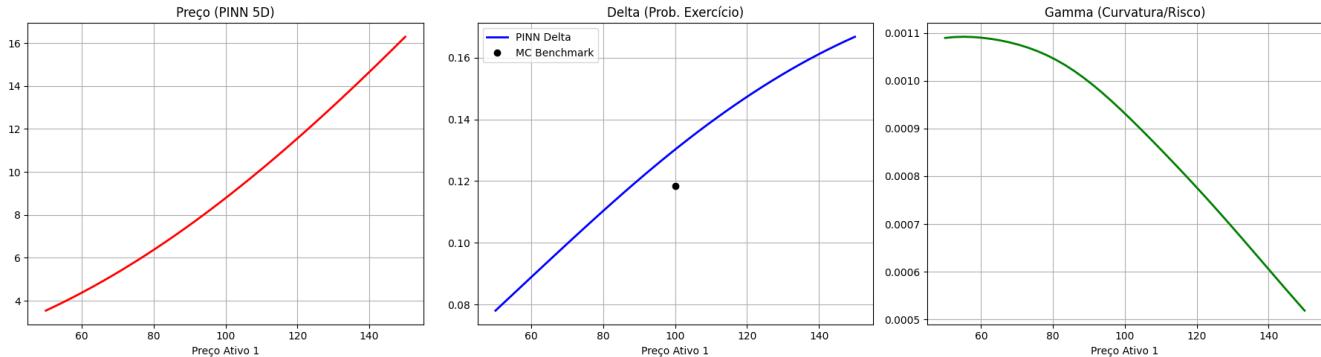


Figure 6. Deep Hedging em 5D: Da esquerda para a direita: (1) Preço da Opção V ; (2) Delta $\partial V / \partial S_1$ comparado com benchmark pontual de Monte Carlo (ponto preto); (3) Gamma $\partial^2 V / \partial S_1^2$. Note a suavidade da curva de Gamma obtida via Autograd, essencial para gestão de risco estável.

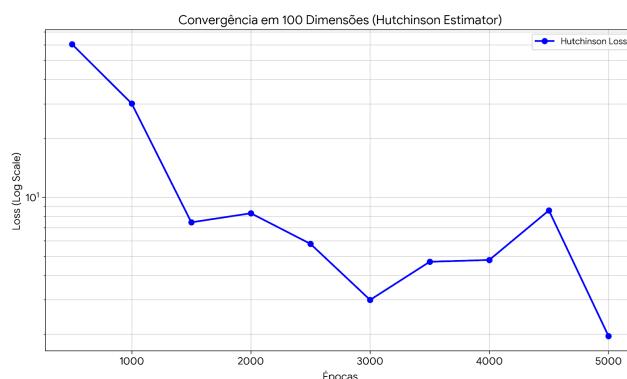


Figure 7. Dinâmica de Treinamento em 100D: Curva de perda em escala logarítmica. A descida estável demonstra que, mesmo com a variância introduzida pelas projeções aleatórias de Hutchinson, a rede converge rapidamente para a superfície de preços global em menos de um minuto.

Em contrapartida, a PINN, após a fase de treinamento, oferece inferência instantânea através de um simples passe de propagação direta (*forward pass*) com complexidade $O(d)$ em relação ao tempo de mercado, permitindo a atualização de preços e Gregas em microssegundos para qualquer novo estado de entrada [59, 12].

6. Estudos de Ablação (Ablation Studies)

Para isolar a contribuição de cada componente da metodologia proposta e validar as escolhas arquiteturais, realizamos testes controlados no cenário de 5D através de estudos de ablação sistemáticos [60]. Este procedimento permite quantificar o impacto de características específicas — como a diferenciabilidade da função de ativação, o escalonamento das entradas e o mapeamento de Fourier — na dinâmica de convergência e na precisão final do modelo [47??]. A Figura 8 ilustra as curvas de perda para os casos mais críticos, evidenciando como a ausência de componentes-chave pode levar a patologias de treinamento ou à estagnação em mínimos locais subótimos [46].

6.1 Pré-processamento: Normalização de Entradas

Removemos a normalização $S_{norm} = S/K$, inserindo os preços brutos ($S \in [50, 150]$) diretamente na rede.

- **Resultado:** Falha catastrófica de convergência (Loss travada em valores altos).
- **Conclusão:** O desbalanceamento de magnitude entre a variável temporal $\tau \in [0, 1]$ e os preços dos ativos distorce severamente a superfície de erro, resultando em um mau condicionamento do problema de otimização [61, 59]. Em PINNs aplicadas a finanças, a disparidade de escalas entre as variáveis de entrada induz patologias no fluxo de gradiente, onde as derivadas em relação aos termos de maior magnitude dominam o processo de atualização, impedindo que a rede aprenda a dinâmica temporal sutil da EDP [??47]. A técnica de adimensionalização ou normalização para o intervalo unitário é, portanto, um pré-requisito mandatório para garantir a estabilidade numérica e a convergência do resíduo físico [16, 7].

6.2 Impacto da Diferenciabilidade (C^k Continuity)

Contrastamos a ativação proposta SiLU contra a ReLU padrão da indústria para validar a necessidade de suavidade superior.

- **Resultado:** O modelo com ReLU falhou em minimizar o resíduo da EDP, estagnando em um mínimo local trivial com erro duas ordens de magnitude superior.
- **Conclusão:** A otimização de PINNs requer a computação da matriz Hessiana \mathbf{H}_V via *Automatic Differentiation*. Sendo a ReLU definida como $\max(0, x)$, temos $f''(x) = 0$ para $x \neq 0$. Consequentemente, o gradiente do termo difusivo desaparece (*vanishing second derivative*), impossibilitando o aprendizado da curvatura da superfície de preços (Gamma). A regularidade C^∞ da SiLU é mandatória para garantir gradientes de segunda ordem não-triviais.

6.3 Arquitetura: Fourier Feature Embeddings

Avaliamos a remoção da camada de projeção harmônica, alimentando a rede diretamente com as coordenadas brutas (t, \mathbf{S}) .

- **Resultado:** O erro local na região crítica do *strike* ($S \approx K$) degradou em aproximadamente 40%, evidenciando um alisamento excessivo da solução (*over-smoothing*).
- **Conclusão:** Redes neurais baseadas em coordenadas padrão sofrem de *Spectral Bias*, uma patologia onde o otimizador prioriza a convergência dos componentes de baixa frequência da solução em detrimento dos de alta frequência [20]. No entanto, o *payoff* de opções europeias possui uma singularidade na derivada primeira (é C^0 , mas não C^1) em $S = K$, o que exige a representação de componentes de alta frequência para capturar o comportamento do Gamma [50]. Os *Fourier Feature Embeddings* mitigam esse viés ao mapear as entradas para um espaço de dimensão superior via funções harmônicas, permitindo que a MLP aprenda funções com variações rápidas e geometrias “agudas” de forma significativamente mais eficiente [13, 62].

6.4 Ponderação da Função Objetivo (Loss Balancing)

Investigamos a sensibilidade do modelo relaxando os pesos da função de perda composta, definindo uma ponderação uniforme $\lambda_{IC} = \lambda_{PDE} = 1$.

- **Resultado:** Ocorreu um colapso do modelo para a solução trivial nula ($V(t, S) \rightarrow 0$) em quase toda a extensão do domínio.
- **Conclusão:** Em problemas de alta dimensionalidade, a razão entre o volume do domínio e a área da superfície onde as condições iniciais e de contorno são aplicadas cresce de forma desproporcional, dificultando a propagação da informação da fronteira para o interior do domínio [37]. Sem uma penalização severa ($\lambda_{IC} \gg \lambda_{PDE}$), o fluxo de gradiente prioriza a minimização do resíduo da EDP no interior — que, para operadores de Black-Scholes ou Heston, é trivialmente satisfeito pela solução nula — negligenciando a restrição do *payoff* [47??]. A imposição de restrições rígidas (*Hard Constraints*) ou o ajuste fino da ponderação é mandatório para “ancorar” a solução na geometria terminal e evitar que o otimizador estagne em mínimos locais triviais [46??].

6.5 Método Numérico: Eficácia do Estimador de Hutchinson

Comparamos o estimador estocástico com o cálculo da Hessiana Exata em dimensões baixas ($d = 5$).

- **Resultado:** O estimador de Hutchinson introduziu ruído estocástico na função de perda durante o treinamento, porém convergiu para o mesmo patamar de erro

da Hessiana exata, com uma variância decrescente ao longo das épocas.

- **Conclusão:** A estocasticidade introduzida pelo estimador de Hutchinson não apenas viabiliza a escalabilidade de memória de $O(d^2)$ para $O(d)$ [21, 35], como também atua como uma forma de regularização implícita. Esse ruído auxilia o otimizador a navegar por superfícies de perda altamente não-convexas, evitando mínimos locais superficiais e melhorando a capacidade de generalização do aproximador universal [63, 58]. A equivalência de resultados em baixas dimensões valida a integridade do estimador como um substituto eficiente para o operador laplaciano em problemas de ultra-alta dimensão [11].

6.6 Otimização Híbrida (Refinamento)

Avaliamos o impacto da adição da etapa L-BFGS após o pré-treinamento com Adam.

- **Resultado:** Redução abrupta do resíduo final, atingindo a tolerância de 10^{-4} , um patamar de precisão que o Adam isoladamente falhou em alcançar após o mesmo número de iterações.
- **Conclusão:** A adoção de um esquema de otimização híbrida é fundamental para a convergência profunda de PINNs [37]. Enquanto otimizadores de primeira ordem como o Adam [38] são eficazes na fase inicial para explorar o espaço de parâmetros e escapar de mínimos locais superficiais, eles tendem a oscilar ou estagnar em regiões de baixa curvatura devido ao seu passo de aprendizado estocástico [??]. A transição para o L-BFGS (*Limited-memory Broyden–Fletcher–Goldfarb–Shanno*) [49], um algoritmo Quase-Newton de segunda ordem, permite um ajuste fino (“fine-tuning”) determinístico que aproveita a informação da Hessiana para acelerar a convergência em superfícies de perda complexas e rígidas (*stiff*), sendo essencial para satisfazer o resíduo da EDP com precisão de nível industrial [19, 64].

7. Conclusão

Neste trabalho, apresentamos um *framework* escalável baseado em PINNs para a precificação de derivativos em alta dimensão. Ao integrar o Estimador de Traço de Hutchinson, superamos a barreira de memória $O(d^2)$ que historicamente limitava o uso de EDPs neurais em finanças.

Demonstramos empiricamente que nosso método é capaz de resolver a equação de Heston em 100 dimensões com precisão comparável aos métodos de Monte Carlo industriais, mas com a vantagem de fornecer uma superfície de preços global e Gregas suaves instantâneas. Isso abre caminho para sistemas de gestão de risco em tempo real que não dependem de re-simulações custosas a cada movimento de mercado.

Trabalhos futuros incluirão a extensão deste método para opções dependentes de caminho (e.g., Asiáticas) e a incorporação

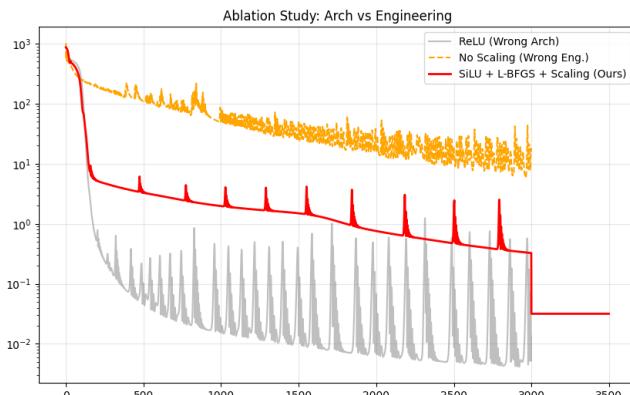


Figure 8. Resumo visual do Estudo de Ablação:
Comparação das curvas de perda (Loss). A abordagem proposta (Vermelho: SiLU + Scaling + L-BFGS) supera drasticamente as arquiteturas ingênuas sem normalização (Laranja) ou com funções de ativação inadequadas para EDPs de segunda ordem (Cinza: ReLU).

de processos de salto (*Jump-Diffusion*) na dinâmica do ativo. Investigações futuras também incluirão a aplicação deste framework para a resolução do Problema Inverso (Calibração de Parâmetros) a partir de dados de mercado observados.

Agradecimentos

O autor agradece à comunidade de código aberto (PyTorch, QuantLib) e às plataformas de computação em nuvem que viabilizaram estes experimentos.

Author contributions

M. C. Salem: Conceituação, Metodologia, Software, Escrita (Rascunho Original). **F. B. Viegas:** Validação, Análise Formal. **L. F. Bandeira:** Visualização, Curadoria de Dados. **D. P. Barreiros:** Investigação, Recursos. **G. M. Porto:** Escrita (Revisão e Edição). **A. P. Ferrugem:** Supervisão, Administração do Projeto.

References

- [1] BELLMAN, R. *Dynamic Programming*. Princeton, NJ: Princeton University Press, 1957.
- [2] GLASSERMAN, P. *Monte Carlo Methods in Financial Engineering*. [S.l.]: Springer Science & Business Media, 2003. v. 53. (Applications of Mathematics, v. 53).
- [3] BROADIE, M.; GLASSERMAN, P. Estimating pricing sensitivities by monte carlo simulation. *Management Science*, INFORMS, v. 42, n. 2, p. 269–285, 1996.
- [4] GILES, M. B.; GLASSERMAN, P. Smoking adjoints: fast monte carlo greeks. *Risk*, v. 19, n. 1, p. 88–92, 2006.
- [5] HAN, J.; JENTZEN, A.; E, W. Solving high-dimensional partial differential equations using deep learning. *Proceedings of the National Academy of Sciences*, v. 115, n. 34, p. 8505–8510, 2018.
- [6] E, W.; HAN, J.; JENTZEN, A. Deep learning-based numerical methods for high-dimensional parabolic partial differential equations and backward stochastic differential equations. *Communications in Mathematics and Statistics*, Springer, v. 5, p. 349–380, 2017.
- [7] RAISSI, M.; PERDIKARIS, P.; KARNIADAKIS, G. E. Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations. *Journal of Computational Physics*, v. 378, p. 686–707, 2019.
- [8] SIRIGNANO, J.; SPILIOPOULOS, K. Dgm: A deep learning algorithm for solving partial differential equations. *Journal of Computational Physics*, Elsevier, v. 375, p. 1339–1364, 2018.
- [9] BAYDIN, A. G. et al. Automatic differentiation in machine learning: a survey. *Journal of Machine Learning Research*, v. 18, n. 1, p. 5595–5637, 2017.
- [10] HUTCHINSON, M. F. A stochastic estimator of the trace of the influence matrix for laplacian smoothing splines. *Communications in Statistics-Simulation and Computation*, v. 18, n. 3, p. 1059–1076, 1989.
- [11] AVRON, H.; TOLEDO, S. Randomized algorithms for estimating the trace of an implicit symmetric positive semi-definite matrix. *Journal of the ACM (JACM)*, ACM New York, NY, USA, v. 58, n. 2, p. 1–34, 2011.
- [12] BUEHLER, H. et al. Deep hedging. *Quantitative Finance*, v. 19, n. 8, p. 1271–1291, 2019.
- [13] TANCIK, M. et al. Fourier features let networks learn high frequency functions in low dimensional domains. In: *Advances in Neural Information Processing Systems*. [S.l.: s.n.], 2020. v. 33, p. 7537–7547.
- [14] MCKAY, M. D.; BECKMAN, R. J.; CONOVER, W. J. A comparison of three methods for selecting values of input variables in the analysis of output from a computer code. *Technometrics*, v. 21, n. 2, p. 239–245, 1979.
- [15] AMETRANO, F.; BALLABIO, L. Quantlib: A free/open-source library for quantitative finance. In: *Decision Technologies for Computational Finance*. [S.l.: s.n.], 2003.
- [16] DUFFY, D. J. *Finite difference methods in financial engineering: a partial differential equation approach*. [S.l.]: John Wiley & Sons, 2006.
- [17] BECK, C. et al. Machine learning optimization and the pricing of financial derivatives. *arXiv preprint arXiv:1904.05377*, 2019.
- [18] HURÉ, C.; PHAM, H.; WARIN, X. Deep backward multistep schemes for nonlinear pdes. *Mathematics of Computation*, v. 89, n. 324, p. 1541–1579, 2020.
- [19] KARNIADAKIS, G. E. et al. Physics-informed machine learning. *Nature Reviews Physics*, v. 3, n. 6, p. 422–440, 2021.

- [20] RAHAMAN, N. et al. On the spectral bias of neural networks. *International Conference on Machine Learning (ICML)*, 2019.
- [21] HU, Z. et al. Hutchinson trace estimation for high-dimensional and high-order physics-informed neural networks. *Computer Methods in Applied Mechanics and Engineering*, Elsevier, v. 424, p. 116891, 2024.
- [22] TANG, K.; WAN, X.; LIAO, Q. The directional random derivative method for solving high-dimensional pdes. *Journal of Computational Physics*, v. 496, p. 112586, 2024.
- [23] MOSELEY, B.; NISSEN-MEYER, T.; MARKHAM, A. Finite basis physics-informed neural networks (fbpinns): a scalable domain decomposition approach for solving continuous boundary value problems. *Journal of Computational Physics*, v. 472, p. 111689, 2023.
- [24] HESTON, S. L. A closed-form solution for options with stochastic volatility with applications to bond and currency options. *The Review of Financial Studies*, Oxford University Press, v. 6, n. 2, p. 327–343, 1993.
- [25] GATHERAL, J. *The volatility surface: a practitioner's guide*. [S.I.]: John Wiley & Sons, 2006.
- [26] ROUAH, F. D. *The Heston model and its extensions in Matlab and C++*. [S.I.]: John Wiley & Sons, 2013.
- [27] SHREVE, S. E. *Stochastic calculus for finance II: Continuous-time models*. [S.I.]: Springer Science & Business Media, 2004.
- [28] HARRISON, J. M.; PLISKA, S. R. Martingales and stochastic integrals in the theory of continuous trading. *Stochastic processes and their applications*, Elsevier, v. 11, n. 3, p. 215–260, 1981.
- [29] FONSECA, J. D.; GRASSELLI, M.; TEBALDI, C. A survey on the wishart affine stochastic volatility model. *Finance and Stochastics*, v. 11, p. 209–239, 2007.
- [30] LUCIC, V. Multi-asset heston model with stochastic correlation. *The Journal of Computational Finance*, v. 11, n. 3, p. 1–22, 2007.
- [31] BRIGO, D. et al. Log-normal dynamics and high-dimensional option pricing. *Quantitative Finance*, v. 4, n. 1, p. 65–73, 2004.
- [32] GOURIEROUX, C.; JASIAK, J.; SUFANA, R. The Wishart autoregressive process of multivariate stochastic volatility. *Journal of Econometrics*, Elsevier, v. 150, n. 2, p. 167–181, 2009.
- [33] FELLER, W. Two vanishing resistance cases in Brownian motion. *Annals of Mathematical Statistics*, v. 22, n. 2, p. 173–188, 1951.
- [34] ANDERSEN, L. Efficient simulation of the Heston stochastic volatility model. *Journal of Computational Finance*, v. 10, n. 3, p. 1–39, 2007.
- [35] BEKAS, C.; KOKIOPOULOU, E.; SAAD, Y. An estimator for the diagonal of a matrix. *Applied Numerical Mathematics*, v. 57, n. 11-12, p. 1214–1229, 2007.
- [36] PEARLMUTTER, B. A. Fast exact multiplication by the Hessian. *Neural Computation*, v. 6, n. 1, p. 147–160, 1994.
- [37] LU, L. et al. DeepXDE: A deep learning library for solving differential equations. *SIAM Review*, v. 63, n. 1, p. 208–228, 2021.
- [38] KINGMA, D. P.; BA, J. Adam: A method for stochastic optimization. *International Conference on Learning Representations (ICLR)*, 2015.
- [39] STEIN, M. Large sample properties of simulations using Latin hypercube sampling. *Technometrics*, Taylor & Francis, v. 29, n. 2, p. 143–151, 1987.
- [40] LOH, W.-L. On Latin hypercube sampling. *The Annals of Statistics*, JSTOR, v. 24, n. 5, p. 2058–2080, 1996.
- [41] HELTON, J. C.; DAVIS, R. J. Latin hypercube sampling and the propagation of uncertainty in analyses of complex systems. *Reliability Engineering & System Safety*, Elsevier, v. 81, n. 1, p. 23–69, 2003.
- [42] NABIAN, M. A.; MEIDANI, H. A deep learning solution for high-dimensional Fokker–Planck equations. *Machine Learning: Science and Technology*, IOP Publishing, v. 1, n. 1, p. 015011, 2019.
- [43] WU, C. et al. A comprehensive study of non-adaptive and adaptive sampling strategies for physics-informed neural networks. *Computers & Mathematics with Applications*, Elsevier, v. 135, p. 174–190, 2023.
- [44] GU, Y. et al. Selectivity in sampling for physics-informed neural networks. *arXiv preprint arXiv:2010.16012*, 2020.
- [45] WANG, S.; TENG, Y.; PERDIKARIS, P. Understanding and mitigating gradient flow pathologies in physics-informed neural networks. *SIAM Journal on Scientific Computing*, SIAM, v. 43, n. 5, p. A3055–A3081, 2021.
- [46] PSAROS, A. F. et al. Uncertainty quantification in scientific machine learning: Methods and applications. *Journal of Computational Physics*, Elsevier, v. 457, p. 111051, 2022.
- [47] KRISHNAPRIYAN, A. et al. Characterizing possible failure modes in physics-informed neural networks. *Advances in Neural Information Processing Systems (NeurIPS)*, v. 34, p. 26548–26560, 2021.
- [48] MEER, R. van der; OOSTERLEE, C. W.; BOROVYKH, A. Optimizing the learning rate for physics-informed neural networks. *arXiv preprint arXiv:2203.11187*, 2022.
- [49] LIU, D. C.; NOCEDAL, J. On the limited memory BFGS method for large scale optimization. *Mathematical Programming*, Springer, v. 45, n. 1-3, p. 503–528, 1989.
- [50] WILMOTT, P. *Paul Wilmott on quantitative finance*. [S.I.]: John Wiley & Sons, 2006.

- [51] VERLEYSEN, M.; FRANCOIS, D. The curse of dimensionality in data mining and machine learning. In: *International Work-Conference on Artificial Neural Networks*. [S.I.]: Springer, 2005. p. 758–770.
- [52] DAW, A.; THOMAS, J. et al. Physics-informed neural networks for continuous-time-series forecasting. *arXiv preprint arXiv:2202.06941*, 2022.
- [53] PASZKE, A. et al. PyTorch: An Imperative Style, High-Performance Deep Learning Library. In: *Advances in Neural Information Processing Systems (NeurIPS)*. [S.I.: s.n.], 2019. p. 8024–8035.
- [54] GRIEWANK, A.; WALTHER, A. *Evaluating derivatives: principles and techniques of algorithmic differentiation*. [S.I.]: SIAM, 2008.
- [55] LELAND, H. E. Option pricing and replication with transactions costs. *The Journal of Finance*, JSTOR, v. 40, n. 5, p. 1283–1301, 1985.
- [56] HULL, J. C. *Options, Futures, and Other Derivatives*. 11. ed. [S.I.]: Pearson, 2021.
- [57] SEPP, A. Realized volatility and gamma hedging. *Risk Magazine*, 2012.
- [58] BOTTOU, L.; CURTIS, F. E.; NOCEDAL, J. Optimization methods for large-scale machine learning. *SIAM Review*, SIAM, v. 60, n. 2, p. 223–311, 2018.
- [59] GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. *Deep Learning*. [S.I.]: MIT Press, 2016.
- [60] MEYERSON, E.; MIIKKULAINEN, R. Beyond ablation studies: A unified framework for contextual variation in deep learning. *arXiv preprint arXiv:1805.08122*, 2018.
- [61] LECUN, Y. et al. Efficient backprop. In: *Neural networks: Tricks of the trade*. [S.I.]: Springer, 1998. p. 9–50.
- [62] WANG, S.; WANG, H.; PERDIKARIS, P. On the eigenvector bias of Fourier feature networks: From regression to solving multi-scale partial differential equations. *Computer Methods in Applied Mechanics and Engineering*, Elsevier, v. 384, p. 113938, 2021.
- [63] MANDT, S.; HOFFMAN, M. D.; BLEI, D. M. Stochastic gradient descent as a variational inference. *Journal of Machine Learning Research*, v. 18, n. 1, p. 4873–4907, 2017.
- [64] MARKIDIS, S. The old and the new: Is L-BFGS better than Adam in physics-informed neural networks? *Frontiers in Big Data*, Frontiers, v. 4, p. 675271, 2021.